



**TECNOLÓGICO
NACIONAL DE MÉXICO**



INSTITUTO TECNOLÓGICO DE CULIACÁN

ING. EN SISTEMAS COMPUTACIONALES

TAREA 1

ALUMNO:

CHRISTIAN NATANAEL AYON ZAZUETA

MATERIA:

INTELIGENCIA ARTIFICIAL

MAESTRO:

ZURIEL DATHAN MORA FELIX

HORARIO

9:00-10:00

Enfoque conexionista

El enfoque conexionista se basa en redes neuronales artificiales inspiradas en el cerebro humano. Este enfoque es capaz de aprender de datos y adaptarse a nuevas situaciones. Se ha utilizado con éxito en aplicaciones como el reconocimiento de imágenes y el procesamiento del lenguaje natural.

Ejemplo

Spotify, uno de los servicios de streaming musical más grandes del mundo, utiliza redes neuronales para personalizar la experiencia de sus usuarios. Uno de sus productos más conocidos es el "Descubrimiento Semanal" (Discover Weekly), una playlist automática que se actualiza cada lunes con canciones que probablemente gustarán al usuario.

Este sistema no funciona con reglas programadas manualmente, sino con algoritmos que aprenden de los patrones de escucha de millones de personas, usando modelos conexionistas.

Spotify aplica el paradigma conexionista mediante técnicas de *deep learning*, utilizando redes neuronales artificiales para personalizar la experiencia musical de cada usuario. Estas redes analizan el historial de reproducción individual y lo combinan con los historiales de otros usuarios con gustos similares. A partir de esta información, las redes neuronales identifican patrones ocultos y relaciones entre canciones, géneros, artistas y comportamientos de escucha.

El aprendizaje se da a través del ajuste de los pesos sinápticos entre nodos, lo que permite que el sistema mejore continuamente sus recomendaciones. Además, Spotify emplea técnicas como Word2Vec, en las que las canciones se representan como vectores numéricos dentro de un espacio multidimensional. Este enfoque permite que el sistema determine la "proximidad" entre canciones, de manera análoga al procesamiento de lenguaje natural, y así recomendar temas similares a los que el usuario ya disfrutaba.

Beneficios:

- **Altísima personalización:** la playlist "Descubrimiento Semanal" se siente única para cada usuario.
- **Mejora constante:** el modelo se entrena y ajusta continuamente con nuevos datos.
- **Escalabilidad:** puede aplicarse a millones de usuarios simultáneamente con una experiencia única para cada uno.

Limitaciones:

- **Dependencia de grandes cantidades de datos:** el sistema necesita datos de millones de usuarios para funcionar correctamente.
- **"Caja negra":** es difícil explicar por qué se recomendó una canción específica.
- **Riesgo de sesgo algorítmico:** podría encerrar al usuario en una "burbuja musical", sin exposición a nuevos géneros o estilos si el modelo no está bien ajustado.

Enfoque simbólico

La inteligencia artificial (IA) simbólica es un subcampo de la IA que se centra en el procesamiento y la manipulación de símbolos o conceptos, en lugar de datos numéricos. El objetivo de la IA simbólica es construir sistemas inteligentes que puedan razonar y pensar como los humanos, representar y manipular el conocimiento y el razonamiento en función de reglas lógicas.

Los algoritmos de IA simbólica funcionan mediante el procesamiento de símbolos, que representan objetos o conceptos del mundo, y sus relaciones. El enfoque principal de la IA simbólica es utilizar la programación basada en la lógica, en la que se utilizan reglas y axiomas para hacer inferencias y deducciones.

Ejemplo

El enfoque simbólico de la inteligencia artificial se basa en representar el conocimiento de forma explícita mediante símbolos, hechos y reglas lógicas, en lugar de depender del aprendizaje automático. Un ejemplo clásico de este enfoque es MYCIN, un sistema experto desarrollado en la década de 1970 para ayudar en el diagnóstico de infecciones bacterianas. MYCIN contaba con una base de conocimientos construida manualmente, donde los expertos médicos colaboraron con ingenieros para codificar reglas del tipo si el paciente tiene fiebre alta y la presión está baja, entonces es probable una infección bacteriana del tipo x. Este conocimiento estaba organizado en forma de reglas if-then (si-entonces), que permitían representar el razonamiento clínico humano de manera estructurada.

Cuando el sistema recibía datos sobre un paciente, su motor de inferencia analizaba esa información utilizando las reglas previamente establecidas para hacer deducciones lógicas. A partir de ello, MYCIN podía sugerir diagnósticos y recomendar tratamientos, como antibióticos adecuados, teniendo en cuenta factores como el tipo de bacteria, las alergias del paciente y otros síntomas relevantes. A diferencia del paradigma conexionista, aquí no se utilizaban redes neuronales ni procesos de aprendizaje automático; todo el conocimiento era proporcionado y estructurado por humanos, siguiendo una lógica simbólica claramente definida.

Beneficios:

- **Transparencia:** las decisiones del sistema son explicables, ya que se basan en reglas conocidas.
- **Control total:** los desarrolladores y expertos saben exactamente cómo se comporta el sistema.
- **Útil en dominios bien comprendidos,** donde las reglas son claras (como ciertos aspectos médicos o legales).

Limitaciones:

- **Difícil de escalar:** crear y mantener miles de reglas manualmente es costoso y lento.

- **Falta de adaptación:** no aprende con el tiempo; si aparece una nueva enfermedad, hay que actualizarlo manualmente.
- **Rigidez:** si el paciente presenta síntomas poco comunes o ambiguos, el sistema podría fallar al no tener una regla específica para ese caso.

Etapas del aprendizaje automático (ML)

1. **Adquisición de datos:** La adquisición de datos es el primer paso en el proceso de aprendizaje automático. Se refiere al acto de reunir y recopilar información relevante de diversas fuentes, tanto internas como externas. Por ejemplo, la empresa tiene posibilidad de capturar las transacciones de los clientes, el tráfico del sitio web o las lecturas de los sensores.
2. **Procesamiento de datos:** El preprocesamiento de datos para el aprendizaje automático (ML) se refiere a la preparación y transformación de datos sin procesar en un formato adecuado para la capacitación de modelos de ML. Es un paso esencial en un proceso de ML (o AI) porque afecta directamente el rendimiento y la precisión de los modelos. El preprocesamiento de datos implica varias técnicas, como limpiar los datos para manejar los valores faltantes, eliminar valores atípicos, escalar características, codificar variables categóricas y dividir los datos en conjuntos de capacitación y pruebas. Estas técnicas son clave para garantizar que los datos estén en un formato consistente y utilizable para los algoritmos de ML.
3. **Entrenamiento del modelo:** El proceso de entrenamiento de un modelo de ML consiste en proporcionar datos de entrenamiento de los cuales aprender a un algoritmo de ML (es decir, el algoritmo de aprendizaje). El término modelo de ML se refiere al artefacto de modelo que se crea en el proceso de entrenamiento. Los datos de entrenamiento deben contener la respuesta correcta, que se conoce como destino o atributo de destino. El algoritmo de aprendizaje encuentra patrones en los datos de entrenamiento que asignan los atributos de los datos de entrada al destino (la respuesta que desea predecir) y genera un modelo de ML que captura dichos patrones.
4. **Evaluación del modelo:** La evaluación de modelos de aprendizaje automático es un proceso destinado a determinar la calidad y eficacia de los modelos desarrollados para diversas tareas predictivas o descriptivas en IA. Se basa en el uso de métricas y técnicas específicas para medir el rendimiento del modelo con datos nuevos, en particular datos que no ha visto durante su entrenamiento. El objetivo principal es garantizar que el modelo funciona satisfactoriamente en condiciones reales y que es capaz de generalizar correctamente más allá de los datos de entrenamiento.

5. **Implementación del modelo:** En el aprendizaje automático, la implementación del modelo es el proceso de integrar un modelo de aprendizaje automático en un entorno de producción existente donde puede tomar una entrada y devolver una salida. Imagina que has pasado varios meses creando un modelo de aprendizaje automático que puede determinar si una transacción es fraudulenta o no con una puntuación f1 casi perfecta. Eso es genial, pero aún no has terminado. Lo ideal sería que tu modelo determine si una transacción es fraudulenta en tiempo real para poder evitar que se realice a tiempo. Aquí es donde entra en juego la implementación del modelo.

Tabla Comparativa de similitudes y diferencias entre aprendizaje automático y el modelo cognitivo.

Similitudes

Aspectos	Modelo Cognitivo	Aprendizaje automático
Basado en redes neuronales	Ambos utilizan unidades interconectadas (neuronas artificiales en ML y neuronas en la cognición) para procesar información	Aprenden patrones a partir de experiencias o datos
Aprendizaje a partir de la experiencia	En el modelo conexionista, el aprendizaje ocurre a través de la modificación de conexiones sinápticas	En aprendizaje automático, se ajustan pesos y parámetros en la red neuronal para minimizar errores
Procesamiento paralelo y distribuido	En el cerebro, la información se procesa en múltiples áreas simultáneamente	En redes neuronales, múltiples nodos procesan datos en paralelo para mejorar el rendimiento
Capacidad de generalización	Ambos pueden predecir o inferir información nueva basada en experiencias previas	Ejemplo: Un niño aprende a reconocer un gato → Una IA aprende a identificar gatos en imágenes

Diferencias

Aspecto	Modelo Cognitivo	Aprendizaje Automático
Propósito	Explicar cómo funciona la cognición humana	Crear modelos para resolver problemas computacionales
Aprendizaje	Modificación de conexiones entre neuronas	Ajuste de pesos mediante optimización matemática
Datos de entrada	Estímulos sensoriales del mundo real	Datos estructurados o no estructurados
Reglas de Aprendizaje	Basado en plasticidad neuronal y refuerzo biológico	Algoritmos como backpropagation y optimización por gradiente
Explicabilidad	No siempre claro cómo el cerebro toma decisiones	Aunque sigue siendo una "caja negra", en ML se pueden analizar pesos y activaciones

Referencias

<https://aws.amazon.com/es/what-is/machine-learning/>

<https://nodd3r.com/blog/como-funciona-el-algoritmo-y-el-sistema-de-recomendacion-de-spotify>

<https://latam.emeritus.org/blogs/la-adquisicion-de-datos-en-el-aprendizaje-automatico/>

<https://www.datacamp.com/es/blog/what-is-symbolic-ai>

<https://telefonicatech.com/blog/mycin-el-comienzo-de-la-inteligencia>